

基于多视图注意力机制的旅游包推荐

● 研究动机

□ 旅游包描述信息复杂

旅游包的描述信息复杂,研究人员很难将其直接应用到现有的推荐系统.然而,传统的方法通过使用旅游包的信息构建**主题模型**(如LDA) 来学习旅游包的表征.事实上,**不同种类**的**旅游包信息**应该以**不同的方式**处理.

□ 用户兴趣动态变化

在线用户的**兴趣**会随着时间**动态**的推移**变化**.直观地看,用户的行为随着时间的推移自然形成点击流,这些**历史**和**当前**的点击流可以动态地揭示用户**长短期偏好**.

标识	标题	目的地	旅游区域	旅游类型
501984218	马尔代夫 椰子岛 Kurumba 4 晚 6 日 香港航空 豪华房 特价	马尔代夫	出境短线	自助游
364669	丽江 香格里拉 6 日游 昆明 丽江 专线 火车票 当地游	云南	国内当地参团	当地参团
270081	苏州 南京 杭州 3 日游 畅游 苏杭 探寻 古都	华东	周边	跟团游

注释: 重要的单词用黑体显示。

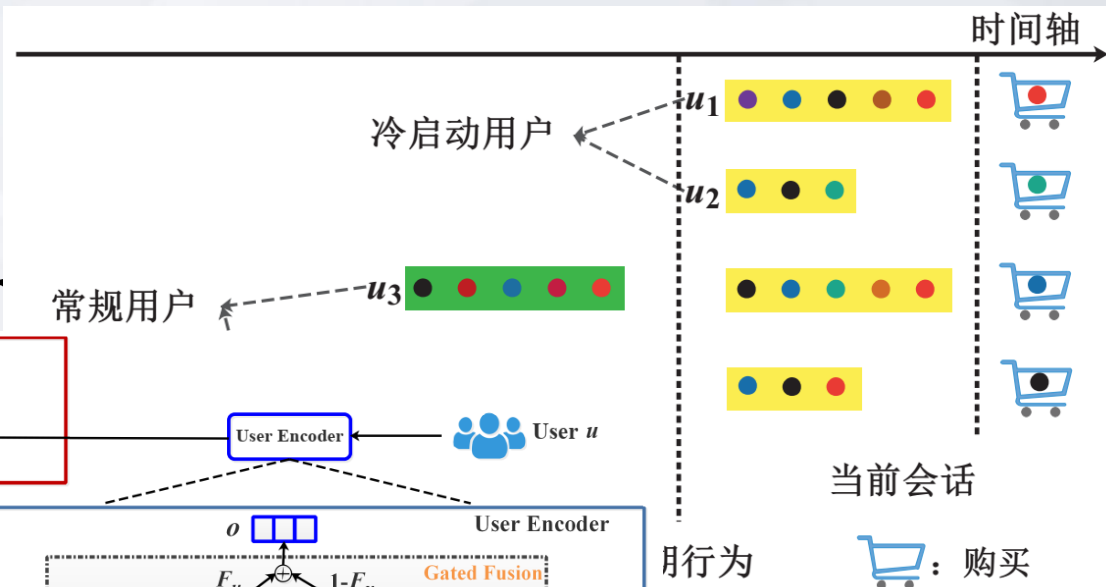
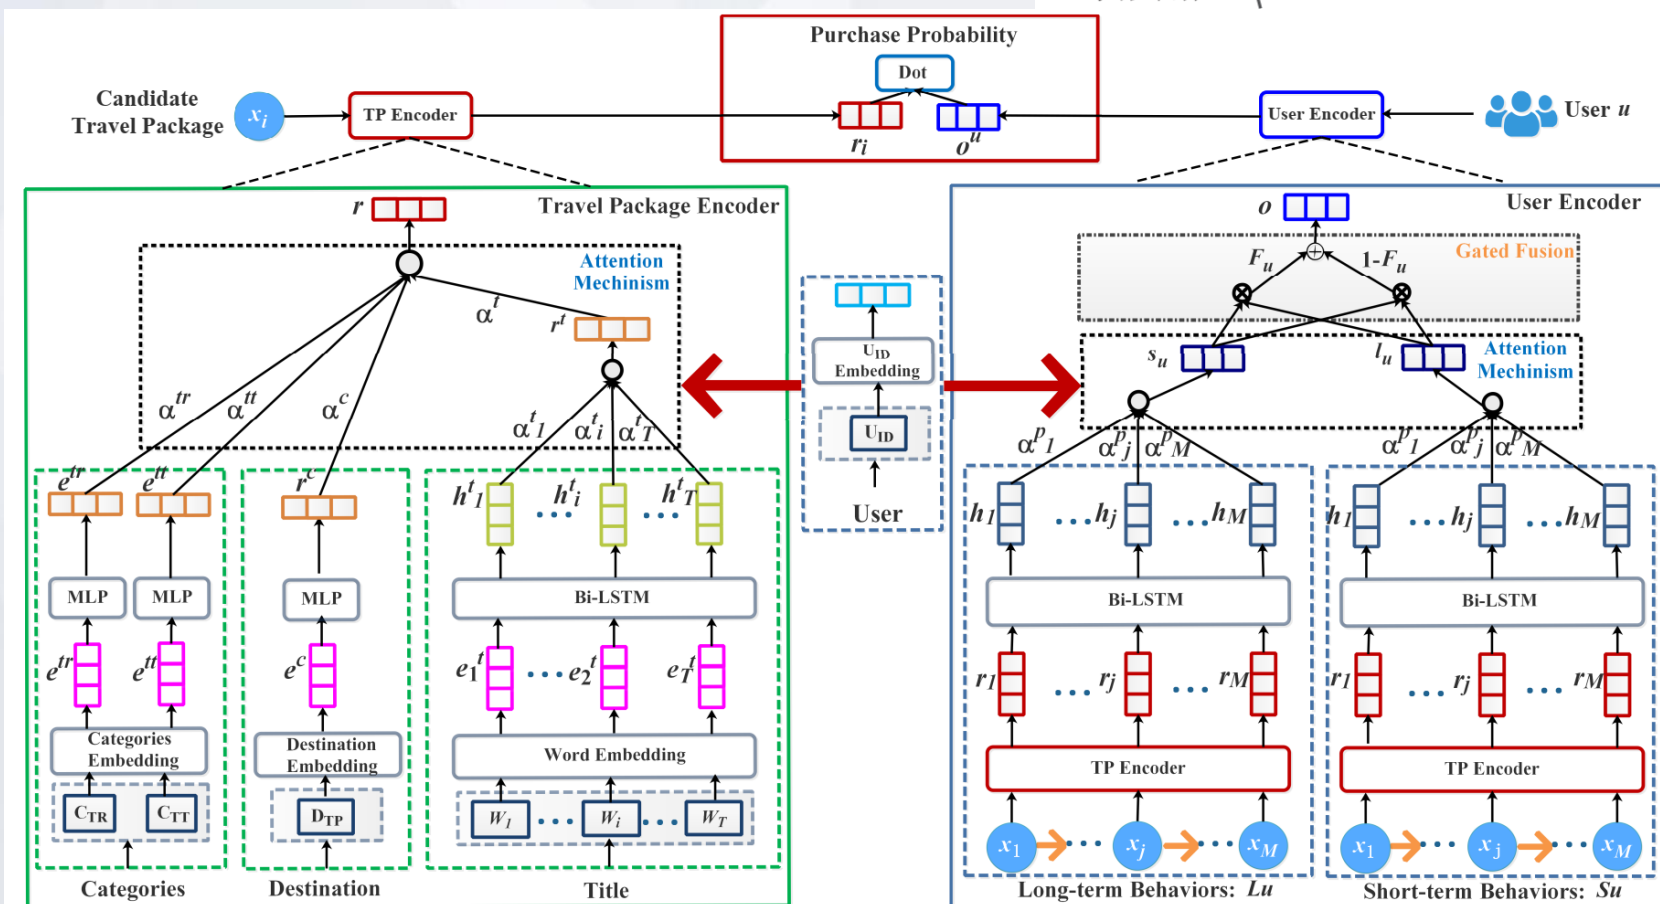


基于多视图注意力机制的旅游包推荐

● 问题定义

□ 长短期(Long-term and Short-term)行为的划分

□ **NATR** (Neural Attentive Travel package Recor



基于多视图注意力机制的旅游包推荐

● 旅游包编码

□ 标题编码(*Title Encoder*)

标题编码模块具有 3 层网络,用于从 Title中学习旅游包的表征:

- ✓ 标题嵌入层, 用于将旅游包的标题转化为一个低维度的稠密向量.
- ✓ 网络是一个双向长短记忆神经网络 (Bi-directional Long Short-Term Memory, Bi-LSTM).
- ✓ 单词层面的注意力网络.

□ 目的地(*Destination Encoder*)

目的地编码模块具有 2 层网络,用于从目的地来学习旅游包的表征:

- ✓ 目的地嵌入层, 其能够将离散型的目的地标识符转化为低维度的表征向量.
- ✓ 多层感知机(Multi-layer Perceptron, MLP)模块.

□ 类别编码(*Categories Encoder*)

类别编码模块具有 2 层网络,用于从类别属性中学习旅游包的表征:

- ✓ 类别嵌入层,将**旅行区域**(TR)和**旅行类型**(TT)的离散标识符分别转换为低维稠密的表征向量.
- ✓ 多层感知机(Multi-layer Perceptron, MLP)模块.

基于多视图注意力机制的旅游包推荐

● 旅游包编码

□ 多视图注意力 (*View-Level Attention*)

多视图注意力网络用于对不同类型的旅游包信息信息量进行建模,从而获得旅游包的**表征向量**,标题视图的**注意力权重**为例,计算方式如下:

$$\begin{aligned} a_t &= \mathbf{q}_u^T \tanh(W_v \mathbf{r}_j^t + b_v), \\ \alpha_t &= \frac{\exp(a_t)}{\exp(a_t) + \exp(a_c) + \exp(a_{tr}) + \exp(a_{tt})}, \end{aligned} \quad (5.7)$$

最终**旅游包** x_j 的**统一表征向量**是带有注意力权重的每一个视图上的表征向量之和,计算方法如下:

$$\mathbf{r}_j = \alpha_t \mathbf{r}_j^t + \alpha_c \mathbf{r}_j^c + \alpha_{tr} \mathbf{r}_j^{tr} + \alpha_{tt} \mathbf{r}_j^{tt}. \quad (5.8)$$

基于多视图注意力机制的旅游包推荐

● 用户偏好编码

用户偏好编码 (*User Preference Encoder*) 模块旨在学习用户的表征向量。

□ 短期偏好编码(*Short-term Preference Encoder*)

短期偏好编码模块通过目标用户的**短期行为数据**来学习其短期偏好表征,针对用户 u 的会话序列,我们借助 **Bi-LSTM** 模型去学习其短期的兴趣动机。

$$\begin{aligned} a_j^p &= \mathbf{q}_u^T \tanh(W_p c_j^p + b_p), \\ \alpha_j^p &= \frac{\exp(a_j^p)}{\sum_{m=1}^M \exp(a_m^p)}, \end{aligned} \quad (5.9)$$

最终用户短期偏好的表征向量可以通过带有注意力权重的旅游包上下文表征向量之和求得:

$$\mathbf{s}_u = \sum_{j=1}^{|S^u|} \alpha_j^p c_j^p. \quad (5.10)$$

□ 长期偏好编码(*Long-term Preference Encoder*)

长期偏好编码模块通过目标用户的**长期行为数据**来学习其长期偏好表征,计算方式同**短期偏好编码**模块,最终的用户长期偏好表征 \mathbf{l}_u 。

基于多视图注意力机制的旅游包推荐

● 用户偏好编码

□ 用户长短期兴趣融合

为了集成用户 u 的长期和短期偏好，我们设计了一种门结构融合网络来衡量长期和短期偏好向量的重要性，并相应地集成这些信息。我们使用与 *View-level Attention* 中一样的用户偏好查询向量 q_u ，并将短期偏好向量 s_u 和长期偏好向量 l_u 作为输入，门结构向量 $F_u \in \mathbb{R}^{D_q}$ 用于控制长短期偏好的贡献度：

$$F_u = \text{sigmoid}(W_q q_u + W_s s_u + W_l l_u + b_u), \quad (5.11)$$

其中 W_q ， W_s ， W_l 和 b_u 是门结构融合网络中的投影参数。最终输出的用户 u 的偏好向量 o_u 可通过以下方法计算：

$$o_u = (1 - F_u) \odot s_u + F_u \odot l_u, \quad (5.12)$$

其中， \odot 是向量内积符号。

基于多视图注意力机制的旅游包推荐

● 模型的训练和测试

$$z_k = \mathbf{o}_u^T \mathbf{r}_j, \quad (5.1)$$

在模型训练阶段，对于用户 u 的短期行为 \mathcal{S}^u 和长期行为 \mathcal{L}^u 而言，积极的标签是下一个真实购买的旅游包 x_j^u 。而消极的标签是从 \mathcal{X} 中除去 x_j^u 进行 log-uniform 采样形成的旅游包集合。在获得用户偏好向量 \mathbf{o}^u 和旅游包的表征向量 \mathbf{r}_j 之后，候选旅游包 $\mathbf{z} = \{z_1, z_2, \dots, z_{|\mathcal{K}|}\}$ 中的旅游包推荐分值 z_k 可以通过公式 5.1 计算得出，其中 \mathcal{K} 是从 \mathcal{X} 抽样的包含积极和消极标签的子集， $\hat{\mathbf{y}} = \{\hat{y}_1, \hat{y}_2, \dots, \hat{y}_{|\mathcal{K}|}\}$ 是 \mathcal{K} 个旅游包的预测概率。然后我们应用 softmax 函数去获取 NATR 模型的输出，即 $\hat{\mathbf{y}} = \text{softmax}(\mathbf{z})$ ，其中 $\hat{\mathbf{y}}$ 是旅游包在会话 \mathcal{S}^u 中被购买的概率。

$$\mathcal{L}(\hat{\mathbf{y}}) = - \sum_{x_j \in \mathcal{K}} y_j \log(\hat{y}_j), \quad (5.13)$$

其中 y_j 是旅游包 x_j 被真实购买的概率分布，具体而，如果 x_j 是积极标签，则 $y_j = 1$ ，反之 $y_j = 0$ 。

注释：我们借助 Adam 优化器来最小化损失函数，从而将 NATR 模型中的参数调为最优配置。

基于多视图注意力机制的旅游包推荐

● 数据来源

本研究中涉及的点击流数据跨时两个月(2013 年 7 月和 8 月),分别记为 D_1 和 D_2 .然后,我们将两个数据集中前 29 天的数据用于训练,其余 2 天的数据用于测试.为了保证实验结果的可靠性,我们进行了相关预处理操作: (i) 为了关注于能够反映用户偏好的产品页面(旅游包) 上的交互,我们过滤掉了大量的非产品页面,如用户访问的主页和匿名页面; (ii) 我们过滤掉了长度小于 2 的用户短期交互(当前会话) 和出现次数小于 5 的项目.

数据集	类型	时间	# 用户	# 项目	# 记录	# 会话	S.Len	L.Len	# 购买项目
D_1	训练集	07.01-07.29	22,699	24,834	420,315	25,988	4.86	11.32	6,101
	测试集	07.30-07.31	1,699	7,971	38,559	1,862	4.46	16.25	1,097
D_2	训练集	08.01-08.29	25,704	18,419	422,512	31,754	4.81	9.64	6,348
	测试集	08.30-08.31	1,028	4,402	16,045	1,112	4.63	9.80	780

注释: (1) “#” 代表目标实体的数量;
(2) “S.Len” 和 “L.Len” 分别代表短期和长期点击流的平均长度。

基于多视图注意力机制的旅游包推荐

● 总体性能评价及描述

我们将**NATR**方法与四种传统推荐方法(即**POP**,**UCF**,**ICF**和**SVD**),以及四种最先进的基于神经网络的推荐方法(即**CDL**,**DeepFM**,**BINN**和**SDM**)进行对比.此外,还包括NATR模型的两个精简版本(**NATR-NoL**和**NATR-NoA**).

□ 总结:

- ✓ 基于**神经网络的协同过滤和矩阵分解方法**(即 CDL 和DeepFM)明显**优于传统方法**(如 Item-NN、UCF 和 SVD).
- ✓ 使用了**基于 RNN 的神经网络方法**(如 BINN,SDM和NATR) **超过**大多数使用**基于协同过滤和矩阵分解的神经网络方法**(CDL 和 DeepFM).
- ✓ **带有长期偏好学习的基于RNN模型**(即 BINN,SDM和NATR)优于那些未带有的模型(即 CDL,DeepFM和NATR-NoL).
- ✓ 带有**注意力机制的基于 RNN 模型**(即 SDM 和 NATR)的表现优于多数**没有注意力机制的模型**(如 BINN 和 NATR-NoA).

模型	D_1			D_2		
	HR@20 (%)	Item-c@20 (%)	MRR@20 (%)	HR@20 (%)	Item-c@20 (%)	MRR@20 (%)
POP	8.13	0.35	1.92	9.05	0.35	1.96
ICF	4.88	13.72	1.11	5.30	14.52	1.20
UCF	33.06	31.30	7.49	36.54	31.55	8.67
SVD	18.69	16.43	5.31	21.20	16.78	5.92
CDL	38.91	36.33	19.53	39.12	38.57	12.95
DeepFM	39.62	38.51	17.78	39.95	41.67	18.73
BINN	40.61	41.18	25.33	41.94	48.05	17.26
SDM	44.24	45.25	23.56	43.30	53.59	21.19
NATR-NoL	38.41	37.59	19.53	37.09	38.47	16.21
NATR-NoA	42.32	43.84	23.59	41.87	42.36	18.91
NATR	48.39	53.14	28.35	47.21	51.92	22.41

注释: HR@20 和 Item-c@20 分别代表 HitRate@20 和 Item-coverage@20。

基于多视图注意力机制的旅游包推荐


● 多视图学习和注意力机制有效性

□ 多视图学习方法的有效性

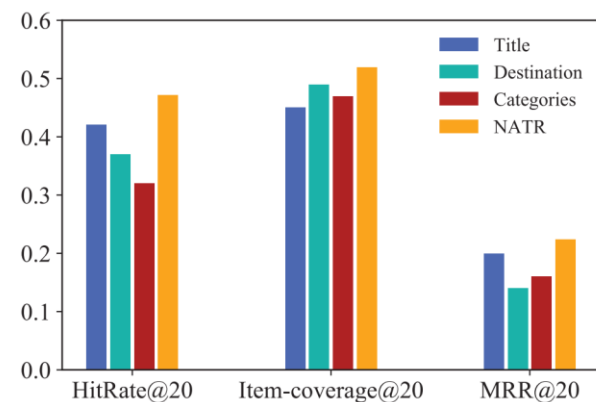
- ✓ 带有**标题视图**的模型比带有目的地或类别视图的模型具有**更好**的性能.
- ✓ **目的地**和**类别视图**也可以为旅游包个性化推荐**提供丰富信息**.
- ✓ **融合所有三个视图的模型**(即整个NATR模型)可以进一步**提高**推荐性能.

□ 注意力网络的有效性

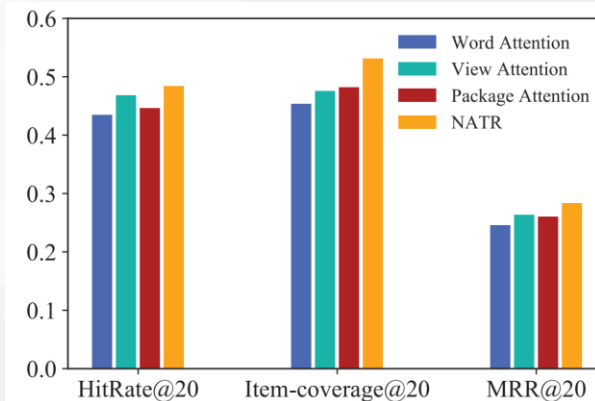
- ✓ **单词层面的注意力网络**可以有效地提升我们方法的性能.
- ✓ **视图层面的注意力**也可以提升我们方法的性能.
- ✓ **旅游包层面的注意力网络**对NATR的性能也很重要.



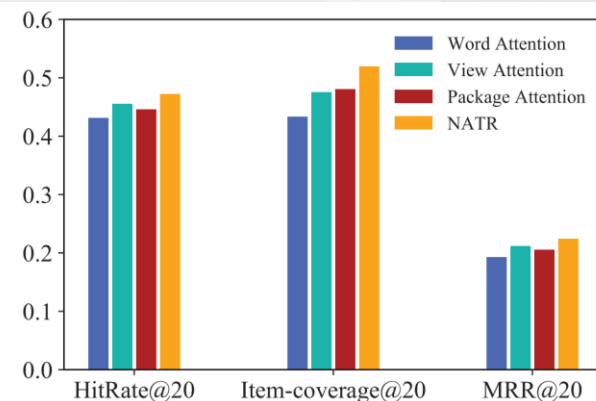
(a) D_1



(b) D_2



(a) D_1



(b) D_2

基于多视图注意力机制的旅游包推荐

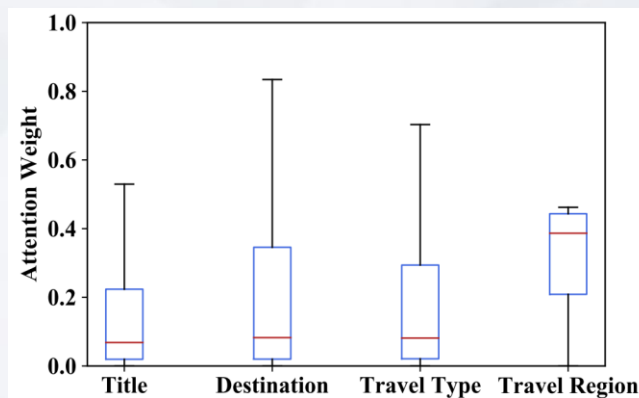
● 注意力权重的可视化

□ 视图层面的注意力权重可视化

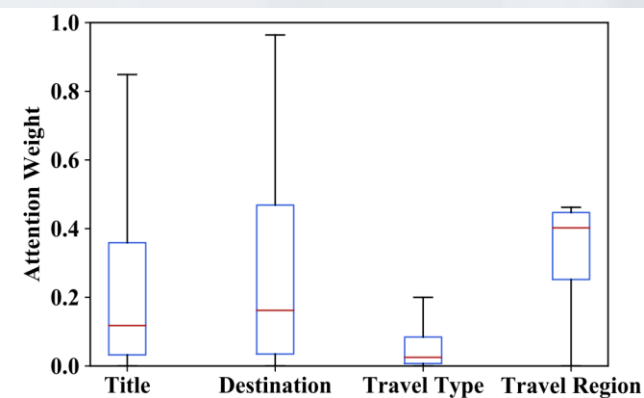
- ✓ 旅游区域上的注意力权重显著高于标题、目的地和旅游类型.
- ✓ 旅游目的地上的注意力权重也略高于标题和旅游类型.
- ✓ 旅游标题的注意力权重最低.

□ 用户长短期偏好的注意力权重可视化

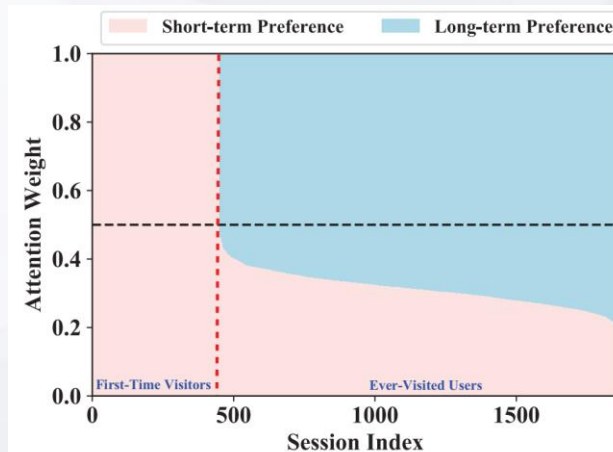
- ✓ First-Time Visitors的长短期偏好:短期偏好权重为1.
- ✓ Ever-Visited Users的长期偏好的注意力权重明显高于短期偏好(普遍高于0.5). 对于此类用户来说, 长期偏好对于在线用户表达学习更加重要. 因此, 将用户长期行为和短期行为进行融合学习至关重要.



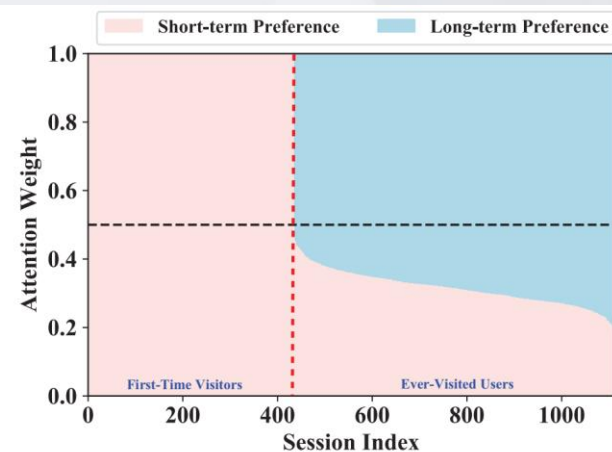
(a) D_1



(b) D_2



(a) D_1



(b) D_2


基于多视图注意力机制的旅游包推荐

● 新用户冷启动问题


在我们的旅游数据集中,超过**87.6%**的用户在当前点击流会话中浏览了**不到10个**旅游包.为此,我们从测试数据集中提取这些冷启动用户,并重点检查NATR模型在这些引起冷启动问题的新用户上的推荐性能.

总结:


- ✓ 在大多数情况下**NATR**模型**明显优于基准方法**.
- ✓ 随着**用户会话长度的增加**,NATR模型在推荐性能上有了更大的提升.
- ✓ **所有基于神经网络的模型**都表现出了**强大的能力**.




(a) HitRate@20 on D_1




(b) Item-coverage@20 on D_1




(c) MRR@20 on D_1



(d) HitRate@20 on D_2



(e) Item-coverage@20 on D_2



(f) MRR@20 on D_2